PRESENTER GUIDE · 30 MIN

بررسی روش‌های حفظ حریم خصوصی داده‌های شخصی در یادگیری فدرال برای اینترنت اشیا

راهنمای اسلاید به اسلاید برای دو ارائه‌دهنده؛ هر اسلاید شامل پیام کلیدی، دلیل وجود اسلاید و ربطش با قبل، متن پیشنهادی گفتار، نکته‌های اجرا و انتقال به اسلاید بعد است. زمان کل ۳۰ دقیقه است و برای چاپ A4 تنظیم شده است.

۲۰ اسلاید · ۳۰:۰۰ دقیقه · ۲ ارائه‌دهنده · هر اسلاید یک صفحهٔ چاپ

د

دیانا صباحی · ۱۵:۳۰

اسلایدهای ۱–۴، ۸–۱۰ و ۱۵–۱۷

م

موژان شجاعی · ۱۴:۳۰

اسلایدهای ۵–۷، ۱۱–۱۴ و ۱۸–۲۰

نقشهٔ زمانی

جمع: ۳۰:۰۰

ردیف	اسلاید	گوینده	زمان
۱	جلد	دیانا	۰:۳۰
۲	فهرست مطالب	دیانا	۱:۰۰
۳	مقدمه: مسئله، هدف و مسیر	دیانا	۲:۰۰
۴	روش انتخاب مقالات علمی	دیانا	۱:۳۰
۵	اینترنت اشیا چیست و چرا مهم است؟	موژان	۱:۳۰
۶	چرا آموزش متمرکز راهکار مناسبی نیست؟	موژان	۱:۳۰
۷	یادگیری فدرال چگونه کار می‌کند	موژان	۲:۰۰
۸	حریم خصوصی، ویژگی ذاتی یادگیری فدرال نیست	دیانا	۲:۰۰
۹	مدل تهدید	دیانا	۱:۳۰
۱۰	حملات؛ دو دسته	دیانا	۱:۳۰
۱۱	حریم خصوصی تفاضلی	موژان	۲:۰۰
۱۲	رمزنگاری	موژان	۱:۳۰
۱۳	بلاک‌چین	موژان	۱:۳۰
۱۴	تجمیع مقاوم	موژان	۱:۳۰
۱۵	مقایسهٔ روش‌ها در یک نگاه	دیانا	۲:۰۰
۱۶	خانهٔ هوشمند؛ یک معماری ترکیبی	دیانا	۱:۳۰
۱۷	تشخیص نفوذ با یادگیری فدرال	دیانا	۲:۰۰
۱۸	چالش‌ها و مسیر پیش‌رو	موژان	۱:۳۰
۱۹	جمع‌بندی و نتیجه‌گیری	موژان	۱:۰۰
۲۰	منابع و مراجع	موژان	۰:۳۰

دیانا: ۱۵:۳۰ · موژان: ۱۴:۳۰

جمع کل: ۳۰:۰۰

اسلاید به اسلاید

متن گفتار پیشنهادی



۱ جلد

دیانا | مدت: ۰:۳۰ | تجمعی: ۰:۳۰ | **افتتاحیه**

پیام کلیدی: آموزش بدون انتقال داده، و این پرسش که آیا همین برای حریم خصوصی کافی است.

چرا این اسلاید: اولین ۳۰ ثانیه فقط یک کار دارد: مخاطب بفهمد موضوع چیست، چه کسی ارائه می‌دهد و چقدر طول می‌کشد.
ربط با قبل: نقطهٔ شروع است؛ هنوز چیزی گفته نشده که این اسلاید به آن وصل شود.

چه بگویید

این سمینار یک پرسش مهندسی دارد: در اینترنت اشیا داده روی خود دستگاه تولید می‌شود؛ آیا می‌توان مدل را آموزش داد بدون اینکه داده از دستگاه بیرون برود، و آیا همین برای حریم خصوصی کافی است؟

من دیانا صباحی هستم، همراه موژان شجاعی. در سی دقیقه پنج مقالهٔ ۲۰۲۴ و ۲۰۲۵ را مرور می‌کنیم: سه مقالهٔ مروری و دو چارچوب اجرایی.

خروجی ارائه فهرست روش‌ها نیست؛ یک چارچوب انتخاب است: برای هر تهدید، کدام دفاع، با چه تضمینی و با چه هزینه‌ای. در پایان هم می‌گوییم در همین پنج مقاله چه چیزی اندازه‌گیری شده و چه چیزی نه.

تماس چشمی و لبخند | اشاره به عنوان و پژوهشگران

انتقال: دیانا → فهرست مطالب



۲

فهرست مطالب

دیانا | مدت: ۱:۰۰ | تجمعی: ۱:۳۰ | **مسیر ارائه**

پیام کلیدی: شش بخش، و یک ترتیب عمدی: تعریف تهدید قبل از انتخاب دفاع.

چرا این اسلاید: قبل از جزئیات، نقشهٔ مسیر را می‌دهیم تا مخاطب بداند هر بخش چرا هست و کجا تمام می‌شود.
ربط با قبل: ادامهٔ جلد؛ همین پنج بخش، ترتیب اسلایدهای ۳ تا ۱۸ را می‌سازد: مسئله ← راه‌حل ← تهدید ← دفاع ← مثال.

چه بگویید

مسیر ارائه از تعریف مسئله شروع می‌شود و به یک انتخاب مهندسی می‌رسد.

شش بخش: مقدمه و پرسش پژوهش؛ اینترنت اشیا و یادگیری فدرال؛ مدل تهدید و حملات؛ روش‌های حفظ حریم خصوصی؛ مقایسه و دو مطالعهٔ موردی؛ و نتیجه‌گیری.

ترتیب عمدی است. تا وقتی مشخص نکنیم مهاجم چه دسترسی‌ای دارد و چه چیزی می‌خواهد، «دفاع خوب» بی‌معناست؛ پس مدل تهدید قبل از دفاع‌ها می‌آید.

سی دقیقه است؛ اگر زمان کم شد، جزئیات حملات را در پرسش‌وپاسخ توضیح می‌دهیم. اسلایدهای ۱۱ تا ۱۴ ستون فقرات فنی ارائه‌اند.

۳۰ دقیقه را یادآوری کن | به شش بخش اشاره کن

انتقال: دیانا → مقدمه



۳ مقدمه: مسئله، هدف و مسیر

دیانا | مدت: ۲:۰۰ | تجمعی: ۳:۳۰ | مقدمه

پیام کلیدی: یادگیری فدرال انتقال دادهٔ خام را حذف می‌کند، نه کانال اطلاعاتی به‌روزرسانی‌ها را.

چرا این اسلاید: مسئله را دقیق تعریف می‌کند: داده‌های حساس روی دستگاه‌های پراکنده‌اند و جمع‌کردنشان هم گران است هم پرخطر.
ربط با قبل: اولین ایستگاه نقشهٔ فهرست؛ سؤال پژوهش را می‌سازد که کل ارائه به آن جواب می‌دهد.

چه بگویید

داده در اینترنت اشیا روی دستگاه تولید می‌شود: ساعت، دوربین، ترموستات، حسگر خط تولید. در آموزش متمرکز، همین دادهٔ خام به یک سرور می‌رود.

یادگیری، از نظر ریاضی، کمینه‌کردن یک تابع خطاست. مدل پارامترهایی دارد و الگوریتم گرادیان نزولی این پارامترها را در جهتی تغییر می‌دهد که خطا کم شود.

یادگیری فدرال همین کمینه‌سازی را توزیع‌شده انجام می‌دهد: هر دستگاه روی دادهٔ خودش چند گام گرادیان می‌رود و به‌جای داده، پارامترهای به‌روزشده را می‌فرستد؛ سرور میانگین می‌گیرد.

هدف ارائه: بررسی این فرض که «نبودِ انتقال دادهٔ خام» مساوی است با «حفظ حریم خصوصی». روش کار: مرور پنج مقالهٔ ۲۰۲۴–۲۰۲۵ و مقایسهٔ تهدیدها و دفاع‌ها با یک چارچوب ثابت: مدل تهدید، نوع تضمین، هزینه، بلوغ.

پرسش پژوهش: آیا یادگیری فدرال به‌تنهایی حریم خصوصی دادهٔ اینترنت اشیا را تضمین می‌کند؟ پاسخ کوتاه: خیر. دلیل فنی‌اش را در اسلایدهای بعد می‌بینیم: به‌روزرسانی مدل یک بردار عددی است و بردار، اطلاعات دارد.

پاسخ «خیر» را قلاب کن | هدف و روش را جدا بگو

انتقال: دیانا → روش انتخاب مقالات علمی



۴

روش انتخاب مقالات علمی

دیانا | مدت: ۱:۳۰ | تجمعی: ۵:۰۰ | روش‌شناسی

پیام کلیدی: ۲۹۳ رکورد، یک مقاله از زنجیرهٔ ارجاع، پنج مقالهٔ نهایی: سه مرور و دو چارچوب.

چرا این اسلاید: اعتبار ادعاها به منبعشان است؛ اینجا می‌گوییم از ۲۹۳ رکورد به ۵ مقالهٔ نهایی رسیدیم و با چه معیاری.

ربط با قبل: بعد از تعریف مسئله می‌آید تا قبل از هر عدد و ادعا، بگوییم از کجا آمده.

چه بگویید

اعتبار هر ادعا به منبعش است، پس قبل از هر عدد می‌گوییم این پنج مقاله از کجا آمدند.

در ScienceDirect با کلیدواژه‌های federated learning و IoT و privacy/security در بازهٔ ۲۰۲۴–۲۰۲۵ جست‌وجو کردیم؛ ۲۹۳ رکورد بازیابی شد. یک مقالهٔ کلیدی هم از زنجیرهٔ ارجاع همان مقالات اضافه شد.

معیار ورود: داوری همتا، انگلیسی، پیوند واقعی بین یادگیری فدرال و اینترنت اشیا، و تمرکز بر حریم خصوصی یا امنیت؛ معیار خروج: خارج از بازه، غیرداوری، بی‌ارتباط با موضوع، یا نبود متن کامل.

پنج مقاله دو نقش دارند: سه مرور [1]، [2] و [3] نقشهٔ تهدید و دفاع را می‌دهند؛ دو مقالهٔ [4] و [5] چارچوب اجرایی با عدد و معماری‌اند و در مطالعات موردی از آن‌ها استفاده می‌کنیم.

محدودیتش را صریح بگوییم: نمونه هدفمند است، نه مرور نظام‌مند؛ همهٔ نتیجه‌ها فقط دربارهٔ همین پنج مقاله معتبرند.

۲۹۳ و ۵ را بگو | بگو نمونه هدفمند است

انتقال: تحویل: دیانا این بخش را به موژان می‌سپارد.



۵ اینترنت اشیا چیست و چرا مهم است؟

موژان | مدت: ۱:۳۰ | تجمعی: ۶:۳۰ | زمینه

پیام کلیدی: اینترنت اشیا: حسگر + پردازندهٔ کم‌توان + شبکه؛ دادهٔ حساس همان‌جا تولید می‌شود.

چرا این اسلاید: بدون دیدن دستگاه واقعی، محدودیت‌های یادگیری فدرال (باتری، پهنای باند، حریم) انتزاعی می‌ماند.

ربط با قبل: زمینهٔ اسلاید ۳ را ادامه می‌دهد: همان داده‌های حساس، این بار روی حسگر و دوربین و ساعت.

چه بگویید

یک دستگاه اینترنت اشیا سه جزء دارد: حسگر، یک پردازندهٔ کوچک، و رابط شبکه. خروجی حسگر یک بردار عددی است که هر چند ثانیه ساخته می‌شود: دما، ضربان، شتاب، مصرف برق.

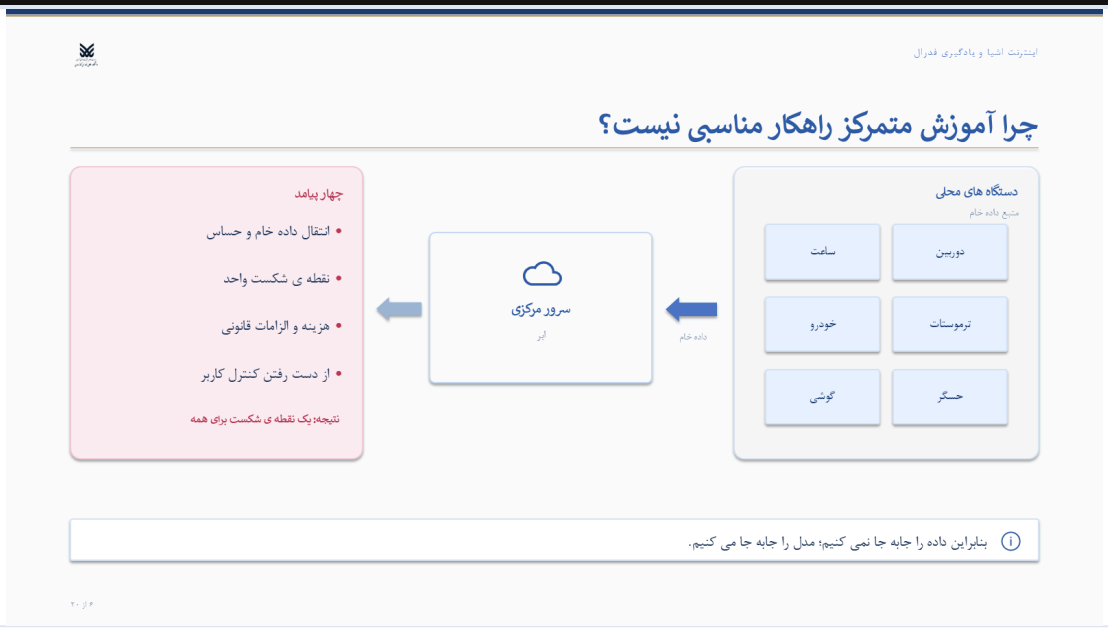
پنج حوزهٔ مهم: خانهٔ هوشمند، سلامت پوشیدنی، شهر هوشمند، صنعت متصل و حمل‌ونقل. در هر پنج مورد، دادهٔ حساس همان‌جاست.

سه محدودیت مهندسی هست که کل ارائه را جهت می‌دهد: پردازندهٔ ضعیف، باتری محدود و پهنای باند کم. همین سه محدودیت تعیین می‌کنند کدام مدل و کدام رمزنگاری روی دستگاه جا می‌شود؛ به این می‌گوییم توان دستگاه.

جمع‌کردن این داده‌ها در یک مرکز سه هزینه دارد: پهنای باند، تأخیر، و بزرگ‌شدن سطح حمله؛ چون یک مرکز، یک هدف با ارزش بالا می‌شود. پس نقطهٔ شروع طراحی حریم خصوصی، همین لایهٔ دستگاه است.

سه جزء و سه محدودیت را بگو | توان دستگاه را تعریف کن

انتقال: موژان → چرا آموزش متمرکز پاسخ نیست؟



۶ چرا آموزش متمرکز راهکار مناسبی نیست؟

موژان | مدت: ۱:۳۰ | تجمعی: ۸:۰۰ | **مسئله**

پیام کلیدی: تمرکز داده، چهار هزینه دارد؛ راه‌حل، جایگزینی داده با مدل است.

چرا این اسلاید: مشکل را ملموس می‌کند: جمع‌کردن داده در یک سرور هم گران است و هم همان جایی است که داده لو می‌رود.
ربط با قبل: پاسخ مستقیم به اسلاید ۵؛ اگر دستگاه‌ها این‌قدر زیاد و داده این‌قدر حساس است، مدل متمرکز جواب نمی‌دهد.

چه بگویید

در آموزش متمرکز، بردار ویژگی از هر دستگاه به سرور می‌رود و مدل آنجا آموزش می‌بیند. چهار پیامد دارد.

اول، انتقال دادهٔ خام: هر بایت داده روی شبکه، یک نسخهٔ اضافه از دادهٔ حساس است. دوم، نقطهٔ شکست واحد: یک پایگاه دادهٔ متمرکز، هدفی است که یک نفوذ، همه‌اش را می‌دهد.

سوم، هزینه و الزامات قانونی: ذخیره و انتقال دادهٔ شخصی، رضایت و کمینه‌سازی داده را لازم می‌کند. چهارم، از دست رفتن کنترل کاربر: بعد از ارسال، کاربر نمی‌داند داده‌اش کجاست و چه مدت می‌ماند.

پس جای داده و مدل را عوض می‌کنیم: داده سر جایش می‌ماند، مدل به دستگاه می‌رود. این ایدهٔ یادگیری فدرال است؛ اما یک سؤال باز می‌ماند: چیزی که از دستگاه بیرون می‌رود، چه اطلاعاتی حمل می‌کند؟

چهار پیامد را بشمار | گذار «مدل را جابه‌جا می‌کنیم»

انتقال: موژان → یادگیری فدرال



۷ یادگیری فدرال چگونه کار می‌کند

موژان | مدت: ۲:۰۰ | تجمعی: ۱۰:۰۰ | راه‌حل

پیام کلیدی: **FedAvg میانگین وزن‌دار پارامترها است؛ وزن هر دستگاه، تعداد نمونه‌هایش.**

چرا این اسلاید: راه‌حل اصلی ارائه؛ مدل به سمت دستگاه می‌رود، نه داده به سمت سرور.

ربط با قبل: جایگزین اسلاید ۶ است: همان مسئله، با معماری برعکس.

چه بگویید

مدل یک تابع پارامتردار است و آموزش یعنی کمینه‌کردن تابع خطا روی دادهٔ آموزشی. یادگیری فدرال همین کار را روی چند دستگاه انجام می‌دهد.

چهار گام: سرور پارامترهای اولیه را می‌فرستد؛ هر دستگاه چند گام گرادیان نزولی روی دادهٔ محلی می‌زند؛ فقط تفاضل پارامترها را برمی‌گرداند؛ سرور میانگین می‌گیرد و دور بعد شروع می‌شود.

این میانگین، میانگین ساده نیست؛ وزن‌دار است و وزن هر دستگاه به تعداد نمونه‌هایش است. اگر یک بیمارستان ده برابر دادهٔ بیشتری داشته باشد، سهمش در مدل مشترک هم بیشتر است.

دو عدد از مقالهٔ [5]: در هر دور، هر دستگاه ۰٫۸۹ ثانیه آموزش می‌بیند و ۳۲۰ کیلوبایت می‌فرستد. یعنی هزینهٔ اصلی، ارتباط است؛ هر دور یک رفت‌وبرگشت شبکه است.

دو ضعف ساختاری هم دارد: دادهٔ دستگاه‌ها هم‌توزیع نیست (non-IID)، پس هر دستگاه به سمت بهینهٔ محلی خودش می‌رود؛ و میانگین به یک بردار پرت حساس است، چون یک دستگاه خرابکار می‌تواند میانگین را بکشد. این دو ضعف، موضوع اسلایدهای ۱۴ و ۱۸ هستند.

میانگین وزن‌دار را بگو | non-IID و بردار پرت

انتقال: تحویل: موژان به دیانا.



۸ حریم خصوصی، ویژگی ذاتی یادگیری فدرال نیست

دیانا | مدت: ۳:۰۰ | تجمعی: ۱۲:۰۰ | **ادعای اصلی**

پیام کلیدی: **گرادیان یک معادلهٔ اضافه در اختیار مهاجم می‌گذارد؛ بازسازی از گرادیان یک نمونه انجام می‌شود.**

چرا این اسلاید: مهم‌ترین پیام ارائه: فدرال‌بودن داده را جابه‌جا نمی‌کند، ولی گرادیان‌ها هنوز حامل اطلاعات‌اند.

ربط با قبل: ضربهٔ بعد از اسلاید ۷؛ مخاطب تازه با یادگیری فدرال آرام گرفته و این اسلاید آن اطمینان را می‌شکند و بقیهٔ ارائه را توجیه می‌کند.

چه بگویید

گرادیان، مشتق تابع خطا نسبت به پارامترهاست؛ برداری به ابعاد مدل. کسی که گرادیان یک نمونه را دارد، معادله‌ای دارد که ورودی در آن ظاهر می‌شود.

Zhu و همکاران در ۲۰۱۹ نشان دادند این معادله حل‌شدنی است: یک ورودی تصادفی فرض می‌کنیم و آن را طوری تغییر می‌دهیم که گرادیانش با گرادیان مشاهده‌شده یکی شود؛ نتیجه، بازسازی تقریبی تصویر یا متن است [6].

چون ابعاد گرادیان از ابعاد نمونه کمتر است، جواب یکتا نیست و بازسازی تقریبی است؛ ولی برای متن و برای چهره کافی است. یعنی «داده جابه‌جا نشد» به معنی «اطلاعات جابه‌جا نشد» نیست.

نکتهٔ دقیق‌تر: این حمله روی گرادیان یک کلاینت یا یک نمونه کار می‌کند، نه روی میانگین تجمیع‌شده. برای همین اولین تصمیم معماری این است: چه کسی به به‌روزرسانی تک‌تک دستگاه‌ها دسترسی دارد؟ اگر سرور آن‌ها را تک‌تک ببیند، خطر بازسازی هست؛ و دو راه‌حلش را بعداً می‌بینیم: تجمیع امن و نویز تفاضلی.

بازسازی از گرادیان فردی | میانگین تجمیع‌شده را جدا کن

انتقال: دیانا → مدل تهدید



۹

مدل تهدید

دیانا | مدت: ۱:۳۰ | تجمعی: ۱۳:۳۰ | **تهدیدها**

پیام کلیدی: سه فرض اعتماد، دو محور تهدید: افشا و دستکاری.

چرا این اسلاید: دفاع بدون شناختن دشمن بی‌معنی است؛ اینجا مشخص می‌کنیم چه کسی، با چه دسترسی، چه می‌خواهد.

ربط با قبل: ادامهٔ اسلاید ۸؛ وقتی گفتیم یادگیری فدرال امن نیست، حالا می‌گوییم از دست چه کسی ناامن است.

چه بگویید

مدل تهدید یعنی فرض‌های صریح دربارهٔ توان و انگیزهٔ دشمن. بدون این فرض‌ها، «امن» یک صفت بی‌معناست.

فرض اول: سرور صادق ولی کنجکاو است. پروتکل را درست اجرا می‌کند، اما به همهٔ به‌روزرسانی‌ها دسترسی دارد؛ هیچ خرابکاری‌ای هم لازم نیست. این قوی‌ترین فرض است.

فرض دوم: کلاینت مخرب؛ داده یا به‌روزرسانی را دستکاری می‌کند. فرض سوم: مهاجم شبکه؛ در مسیر شنود می‌کند یا هویت جعل می‌کند.

مثال سه بیمارستان: سرور جمع و میانگین می‌گیرد و درست عمل می‌کند، اما بردار هر بیمارستان را می‌بیند؛ و همان‌طور که دیدیم، یک بردار می‌تواند نمونه را لو بدهد.

از این سه فرض، دو محور تهدید بیرون می‌آید: حریم خصوصی، یعنی افشای اطلاعات نمونه‌ها؛ و یکپارچگی، یعنی دستکاری مدل. هر دفاعی که در ادامه می‌بینیم روی یکی از این دو محور کار می‌کند، و همین معیار مقایسهٔ آن‌هاست.

سه فرض اعتماد | دو محور تهدید

انتقال: دیانا → حملات



۱۰ حملات؛ دو دسته

دیانا | مدت: ۱:۳۰ | تجمعی: ۱۵:۰۰ | **تهدیدها**

پیام کلیدی: **حملات افشا و حملات دستکاری دو محور جدا هستند؛ سنجه‌شان هم جدا است.**

چرا این اسلاید: از «کی» به «چطور» می‌رسیم: حملات به حریم (نشت اطلاعات) و حملات به مدل (مسموم‌سازی).
ربط با قبل: تفصیل مدل تهدید اسلاید ۹؛ دو دستهٔ حمله، دو دستهٔ دفاع در اسلایدهای ۱۱ تا ۱۴ را می‌سازد.

چه بگویید

حملات افشا هدفشان استخراج اطلاعات از مدل یا از به‌روزرسانی‌هاست. پنج نمونهٔ رایج:

استنتاج عضویت: مدل روی نمونه‌هایی که در آموزش دیده، معمولاً اطمینان بیشتری دارد؛ همین اختلاف اطمینان سنجهٔ حمله است. استنتاج ویژگی: مهاجم یک ویژگی حساس از یک گروه را حدس می‌زند.

معکوس‌سازی مدل: با بهینه‌سازی یک ورودی، نمونه‌ای می‌سازد که مدل با اطمینان بالا در یک کلاس بگذاردش. بازسازی گرادیان: همان کار Zhu، ولی روی به‌روزرسانی. استخراج مدل: با کوئری‌های مکرر، رفتار مدل را تقلید می‌کند.

حملات دستکاری هدفشان خراب‌کردن مدل است: مسموم‌سازی داده، درِ پشتی با یک محرک پنهان، هویت‌های جعلی (سایبیل)، مشارکت بی‌ارزش ولی پاداش‌گیر (بهره‌مندی بدون مشارکت)، و خرابکاری هماهنگ (بیزانسی).

سنجه‌ها را جدا نگه داریم: برای افشا نرخ موفقیت حمله یا AUC؛ برای دستکاری افت دقت روی دادهٔ تمیز. یک روش می‌تواند یکی را کم کند و دیگری را بدتر کند.

سنجهٔ هر محور را بگو | بازسازی از گرادیان فردی

انتقال: تحویل: دیانا به موژان برای دفاع‌ها.



۱۱ حریم خصوصی تفاضلی

موژان | مدت: ۲:۰۰ | تجمعی: ۱۷:۰۰ | دفاع‌ها

پیام کلیدی: **حریم تفاضلی تنها تضمین رسمی است: کران e^{ε} روی تغییر توزیع خروجی، به قیمت نویز و دقت.**

چرا این اسلاید: اولین و تنها دفاع با تضمین ریاضی؛ می‌گوید حتی خروجی مدل هم نباید فرد را لو بدهد.

ربط با قبل: جواب دستهٔ اول حملات اسلاید ۱۰ (نشت از خروجی)؛ از اینجا هر دفاع، یک بخش از تهدید را می‌پوشاند.

چه بگویید

تعریف دقیق: یک مکانیزم، ε-حریم خصوصی تفاضلی است اگر برای هر دو مجموعه داده که فقط در یک رکورد تفاوت دارند، احتمال هر خروجی حداکثر e^{ε} برابر شود؛ δ هم تسامح کوچکی است.

یعنی حضور یک نفر، توزیع خروجی را حداکثر به اندازهٔ یک ضریب محدود عوض می‌کند. پس مهاجم حتی با دانستن بقیهٔ داده‌ها نمی‌تواند با اطمینان بگوید آن یک نفر بوده یا نه. این یک کران ریاضی است، نه یک ادعای شهودی.

در عمل با گرادیان نزولی خصوصی این کار را می‌کنند: گرادیان هر نمونه کلیپ می‌شود، یعنی نرمش حداکثر C، و بعد نویز گاوسی با انحراف معیار متناسب با σC اضافه می‌شود. کلیپ لازم است، وگرنه یک نمونهٔ پرت نویز را بی‌اثر می‌کند.

دو حالت داریم. در حالت مرکزی، نویز یک بار در سرور زده می‌شود و باید به سرور اعتماد کنیم. در حالت محلی، نویز قبل از ارسال روی دستگاه زده می‌شود، پس اعتماد به سرور لازم نیست؛ ولی نویز بیشتری مصرف می‌شود. برای اینترنت اشیا حالت محلی مناسب‌تر است.

نکتهٔ آخر که در عمل تعیین‌کننده است: بودجه جمع‌شدنی است. هر دور بخشی از ε را مصرف می‌کند و با ترکیب k گزارش، ε تقریباً با جذر k رشد می‌کند. دستگاهی که هزار بار می‌فرستد باید بودجه را بین دورها تقسیم کند. ε کوچک‌تر یعنی حریم بیشتر، نویز بیشتر و دقت کمتر؛ این یک انتخاب مهندسی است، نه یک تنظیم دلخواه.

تعریف ε-δ را دقیق بگو | ε را به نویز و دقت وصل کن

انتقال: موژان → رمزنگاری



۱۲ رمزنگاری

موژان | مدت: ۱:۳۰ | تجمعی: ۱۸:۳۰ | دفاع‌ها

پیام کلیدی: رمزنگاری محرمانگی می‌دهد؛ نه کران ε و نه مقاومت به مسموم‌سازی.

چرا این اسلاید: وقتی به سرور هم اعتماد نداریم: محتوا را قبل از فرستادن قفل می‌کنیم.

ربط با قبل: مکمل حریم خصوصی تفاضلی در همان دستهٔ حریم است؛ حریم خصوصی تفاضلی نویز اضافه می‌کند، رمزنگاری پنهان می‌کند.

چه بگویید

وقتی حتی به سرور هم اعتماد نداریم، محتوا را قبل از فرستادن قفل می‌کنیم. چهار ابزار هست.

تجمیع امن: هر جفت دستگاه یک کلید مشترک می‌سازد؛ هر دستگاه به‌روزرسانی‌اش را با ماسک‌هایی جمع می‌زند که در جمع کل صفر می‌شوند. سرور فقط مجموع را می‌بیند، نه سهم هر دستگاه [8].

محاسبات امن: محاسبه بین چند طرف تقسیم می‌شود و هر طرف فقط سهم خودش را می‌بیند؛ امنیت تا وقتی برقرار است که اکثریت همکاری نکنند. رمزنگاری هم‌ریختی: عملیات روی متن رمزشده معادل عملیات روی متن اصلی است؛ مثلاً جمع، که برای میانگین‌گرفتن کافی است.

تقسیم دادهٔ محرمانه: داده به n سهم تقسیم می‌شود و با آستانهٔ k سهم بازسازی می‌شود؛ کمتر از k سهم هیچ اطلاعاتی نمی‌دهد. مقالهٔ مروری [2] همین سه خانوادهٔ رمزنگاری را کنار نویز تفاضلی و آموزش خصمانه دسته‌بندی می‌کند.

دو تفکیک مهم: اول، این‌ها محرمانگی می‌دهند، یعنی سرور محتوا را نمی‌بیند؛ ولی کران ε نمی‌دهند، پس ممکن است از مدل نهایی باز هم اطلاعات فردی در بیاید. دوم، مسموم‌سازی را نمی‌گیرند: عدد غلط هم رمز می‌شود و در جمع می‌نشیند. برای همین رمزنگاری معمولاً با تجمیع مقاوم ترکیب می‌شود.

محرمانگی ≠ کران ε | هزینه‌ها را مقایسه کن

انتقال: موژان → بلاک‌چین



۱۳ بلاک‌چین

موژان | مدت: ۱:۳۰ | تجمعی: ۲۰:۰۰ | دفاع‌ها

پیام کلیدی: بلاک‌چین ثبت و حسابرسی می‌دهد؛ محرمانگی و مقیاس‌پذیری نه.

چرا این اسلاید: مسئلهٔ اعتماد و حسابرسی: چه کسی مدل را ثبت می‌کند و پاداش مشارکت را تقسیم می‌کند؟

ربط با قبل: از حریم به حاکمیت می‌رویم؛ بعد از دو دفاع قبلی، نوبت زیرساخت مشترک بدون مدیر مرکزی است.

چه بگویید

بلاک‌چین از نظر ساختار داده ساده است: هر بلاک، لیستی از تراکنش‌ها به‌همراه هش بلاک قبلی. تغییر یک بلاک، هش همهٔ بلاک‌های بعد را عوض می‌کند و با نسخهٔ بقیهٔ گره‌ها نمی‌خواند؛ همین، دستکاری را لو می‌دهد.

مقالهٔ [4] از همین ساختار در یک چارچوب یادگیری فدرال استفاده می‌کند: هر مشتری مدل آموزش‌دیدهٔ خودش را امضا می‌کند و روی زنجیره ثبت می‌کند؛ قرارداد هوشمند بدون مدیر مرکزی، امضا و سابقهٔ شهرت را بررسی می‌کند و پاداش می‌دهد.

مدل بزرگ روی زنجیره نمی‌رود؛ در IPFS می‌ماند و فقط هش آن ثبت می‌شود. هش یک تابع یک‌طرفه است: تغییر یک بایت مدل، هش را کامل عوض می‌کند و ناسازگاری همان‌جا دیده می‌شود.

هزینه‌اش را هم بگوییم: تأخیر اجماع، توان عملیاتی پایین و هزینهٔ ذخیره‌سازی؛ برای هزاران دستگاه کوچک مقیاس‌پذیر نیست. مهم‌تر این‌که محرمانگی نمی‌دهد: هر چیزی که روی زنجیره نوشته شود برای همه خواندنی است، پس محرمانگی باید جای دیگری تأمین شود.

هش را توضیح بده | تأخیر اجماع

انتقال: موژان → تجمیع مقاوم



۱۴ تجمیع مقاوم

موژان | مدت: ۱:۳۰ | تجمعی: ۲۱:۳۰ | دفاع‌ها

پیام کلیدی: تجمیع مقاوم برای یکپارچگی است و کران خطا می‌دهد، تا وقتی خرابکارها کمتر از نصف باشند.

چرا این اسلاید: جواب این سؤال است: «اگر یک دستگاه خرابکار عدد غلط بفرستد چه؟» قبل از جمع‌زدن، خراب‌ها حذف می‌شوند.

ربط با قبل: در اسلاید ۱۳ دیدیم بلاک‌چین فقط ثبت می‌کند؛ اینجا همان ثبت را فیلتر می‌کنیم تا یک عدد غلط کل مدل را خراب نکند.

چه بگویید

فرض کنید یک کلاینت بردار دلخواه بفرستد. میانگین FedAvg به سمت آن بردار کشیده می‌شود، و اگر نرم بردار بزرگ باشد، عملاً میانگین را کامل می‌برد.

راه‌حل، جایگزین‌کردن میانگین با یک تخمین‌گر مقاوم است. Krum: برای هر به‌روزرسانی، فاصله‌اش تا نزدیک‌ترین همسایه‌ها جمع می‌شود و پایین‌ترین امتیاز انتخاب می‌شود. میانگین پیراسته: در هر بُعد، بزرگ‌ترین و کوچک‌ترین مقدارها حذف می‌شوند. میانه هم گزینهٔ دیگری است.

این روش‌ها کران خطا می‌دهند، اما با یک شرط: تعداد کلاینت‌های خرابکار باید کمتر از نصف باشد. اگر اکثریت خرابکار باشند، هیچ تجمیع‌کنندهٔ آماری نمی‌تواند مدل درست را از داده تشخیص بدهد.

محدودیت مهم: این‌ها فقط یکپارچگی می‌دهند، نه حریم خصوصی. حتی با نویز تفاضلی تعارض دارند: نویز، تشخیص بردار پرت را سخت می‌کند و حذف پرت هم خودش می‌تواند اطلاعات بدهد. پس در سیستم واقعی، این دو را با تنظیم دقیق کنار هم می‌گذارند.

شرط کمتر از نصف | Krum را نام ببر

انتقال: تحویل: موژان به دیانا برای مقایسه.



۱۵ مقایسهٔ روش‌ها در یک نگاه

دیانا | مدت: ۲:۰۰ | تجمعی: ۲۳:۳۰ | **مقایسه**

پیام کلیدی: **انتخاب روش به تهدید، تضمین و هزینه بستگی دارد؛ هیچ ردیفی همهٔ ستون‌ها را ندارد.**

چرا این اسلاید: جواب «کدام روش را انتخاب کنم؟» این است: هیچ‌کدام تنها کافی نیست؛ هر کدام یک مشکل امنیتی را حل می‌کند.
ربط با قبل: جمع‌بندی اسلایدهای دفاعی ۱۱ تا ۱۴؛ همین جدول، مقدمهٔ دو مثال بعدی است.

چه بگویید

این جدول را با سه سؤال بخوانید: چه تهدیدی را می‌بندد؟ چه نوع تضمینی می‌دهد؟ با چه هزینه‌ای؟

ستون «نوع تضمین» مهم‌ترین ستون است. فقط ردیف حریم خصوصی تفاضلی تضمین رسمی دارد، با پارامتر ε؛ بقیه محرمانگی یا یکپارچگی می‌دهند، ولی کران ریاضی روی نشت ندارند. عبارت «بدون ε» یعنی نبود همین کران، نه بی‌اثر بودن.

هزینه‌ها به ترتیب: رمزنگاری همریختی سنگین‌ترین است، چند مرتبه بزرگ‌تر از محاسبهٔ عادی؛ بلاک‌چین هزینه‌اش تأخیر اجماع است؛ تجمیع مقاوم سبک‌ترین.

بلوغ: نویز تفاضلی و تجمیع امن در چارچوب‌های اجرایی [4] و [5] دیده می‌شوند؛ رمزنگاری همریختی روی دستگاه کوچک هنوز جا نیفتاده است.

نتیجهٔ عملی: انتخاب تک‌روشی تقریباً همیشه یک شکاف باز می‌گذارد؛ سیستم‌های واقعی ترکیب می‌کنند. در دو اسلاید بعد دو نمونه از همین ترکیب را می‌بینیم.

ستون تضمین را بخوان | «بدون ε» را توضیح بده

انتقال: دیانا → خانهٔ هوشمند



۱۶ خانهٔ هوشمند؛ یک معماری ترکیبی

دیانا | مدت: ۱:۳۰ | تجمعی: ۲۵:۰۰ | **مطالعهٔ موردی**

پیام کلیدی: معماری مقالهٔ [4]: نویز تفاضلی، امضای مدل، ثبت روی بلاک‌چین و پاداش بر پایهٔ شهرت.

چرا این اسلاید: به‌جای تئوری، معماری مقالهٔ [4] را نشان می‌دهد: نویز تفاضلی، امضا، ثبت روی بلاک‌چین و پاداش شهرت در یک خانه.

ربط با قبل: بعد از جدول مقایسه، اولین مثال واقعی است: همان ترکیب، این بار روی یک معماری منتشرشده.

چه بگویید

این اسلاید معماری مقالهٔ [4] است، نه یک سناریوی خیالی: چارچوب یادگیری فدرال برای لوازم خانگی هوشمند.

چرخه: سازنده مدل اولیه را می‌دهد؛ هر لوازم روی دادهٔ خانه آموزش می‌بیند؛ مشتری مدل را امضا می‌کند و روی بلاک‌چین ثبت می‌کند؛ سازنده فقط مدل‌های معتبر را در تجمیع می‌آورد.

حریم: پیش از خروج پارامترها نویز تفاضلی اضافه می‌شود، و نویسندگان یک تکنیک نرمال‌سازی هم برای همین افزوده‌اند تا نویز، دقت مدل را بیش از حد خراب نکند.

سازوکار شهرت مشکل انگیزه را حل می‌کند: بدون آن، دستگاهی که آموزش نمی‌دهد یا دادهٔ بی‌کیفیت دارد همان پاداش را می‌گیرد. با آن، پاداش به اندازهٔ سهم واقعی در بهبود مدل است و چون ارزیابی روی زنجیره ثبت شده، قابل حسابرسی است.

هزینه: پنج مؤلفه باید هماهنگ باشند؛ تأخیر اجماع، ذخیره‌سازی مدل و پیچیدگی عملیاتی سه هزینهٔ اصلی این معماری‌اند.

بگو از مقالهٔ [4] است | پنج مؤلفه را دنبال کن

انتقال: دیانا → تشخیص نفوذ



۱۷ تشخیص نفوذ با یادگیری فدرال

دیانا | مدت: ۲:۰۰ | تجمعی: ۲۷:۰۰ | **مطالعهٔ موردی**

پیام کلیدی: دقت ۹۵٫۰۵٪، هشدار الکی ۳٫۹٪؛ و هیچ عددی برای نشت حریم خصوصی.

چرا این اسلاید: مثال دوم از حوزه‌ای دیگر است تا معلوم شود این الگو فقط مال یک مقاله نیست.
ربط با قبل: همان الگوی خانه، این بار روی ترافیک شبکه؛ تکرار عمدی تا ببینیم عمومی است.

چه بگویید

این مطالعهٔ موردی، مقالهٔ [5] است: چارچوب PEIoT-DS، یک سیستم تشخیص نفوذ فدرال روی دادهٔ N-BaIoT با ۹ دستگاه.

دو الگوریتم مقایسه شده‌اند: FedAvg و FedAvgM. تفاوتشان مومنتوم است: میانگین متحرک گرادیان‌های قبلی هم در به‌روزرسانی شرکت می‌کند و همین، روی دادهٔ ناهمگون پایدارتر است.

سه عدد کلیدی: دقت ۹۵٫۰۵٪ در برابر ۹۴٫۰۵٪؛ هشدار الکی ۳٫۹٪ در برابر ۵٫۱٪؛ و رسیدن به دقت ۹۰٪ در ۱۷ دور در برابر ۲۴ دور. یعنی هم دقیق‌تر، هم کم‌مزاحم‌تر، هم سریع‌تر.

هزینه: ۰٫۸۹ ثانیه در هر دور و ۳۲۰ کیلوبایت در هر دستگاه؛ برای یک شبکهٔ کوچک قابل تحمل است.

محدودیت را هم بگویم: این اعداد کارایی تشخیص را می‌سنجند، نه حریم خصوصی را. در مقاله نشت اندازه‌گیری نشده و بودجهٔ ε گزارش نشده؛ پس نمی‌دانیم این دقت با چه سطحی از حریم خصوصی به دست آمده.

جدول ۳ را نشان بده | محدودیت مطالعه را بگو

انتقال: تحویل: دیانا به موژان برای جمع‌بندی.



۱۸ چالش‌ها و مسیر پیش‌رو

موژان | مدت: ۱:۳۰ | تجمعی: ۲۸:۳۰ | **جمع‌بندی**

پیام کلیدی: **چهار چالش فنی و سه مسیر عملی؛ همه‌شان محدودیت همین پنج مقاله‌اند.**

چرا این اسلاید: بدون این اسلاید، ادعای «این روش‌ها همه‌چیز را حل می‌کنند» بزرگ‌نمایی است.

ربط با قبل: بعد از دو مثال، برگشت به سطح کلان: محدودیت‌هایی که در اسلایدهای ۱۱ تا ۱۷ دیدیم.

چه بگویید

چالش اول، ناهمگونی داده است: توزیع دادهٔ دستگاه‌ها یکی نیست و به آن non-IID می‌گویند. وقتی هر کلاینت چند گام محلی می‌رود، پارامترهایش به بهینهٔ محلی نزدیک می‌شود و میانگینشان الزاماً به بهینهٔ مشترک نزدیک نیست.

چالش دوم، منابع دستگاه است: حافظه و انرژی، سقف اندازهٔ مدل و انتخاب رمزنگاری را تعیین می‌کنند. چالش سوم، موازنه است: کاهش ε یعنی نویز بیشتر و دقت کمتر؛ این یک منحنی است، نه یک تنظیم.

چالش چهارم، نبود سنجهٔ مشترک است: مقالات دقت و هشدار الکی گزارش می‌کنند، ولی بودجهٔ ε و نرخ موفقیت حمله را کمتر؛ پس مقایسهٔ منصفانه سخت است.

سه مسیر پیشنهادی مقالات: فرستادن بخشی از مدل به‌جای کل آن، رمزنگاری سبک‌وزن، و مدل شخصی‌سازی‌شده برای هر دستگاه به‌جای یک مدل واحد.

و یک شرط غیرفنی: رضایت کاربر و کمینه‌سازی داده. بدون این دو، هیچ معماری فنی‌ای مجاز نیست.

چهار چالش | سه مسیر + قانون

انتقال: موژان → نتیجه



۱۹ جمع‌بندی و نتیجه‌گیری

موژان | مدت: ۱:۰۰ | تجمعی: ۲۹:۳۰ | **جمع‌بندی**

پیام کلیدی: **هدف، پاسخ، و شکاف باقی‌مانده: نشت اندازه‌گیری نشده.**

چرا این اسلاید: جواب صریح پرسش اسلاید ۳ و شکاف باقی‌مانده؛ بدون مرور دوبارهٔ مطالب.

ربط با قبل: بستن مسیر: پرسش اسلاید ۳ اینجا پاسخ می‌گیرد و محدودیت‌های ۱۷ و ۱۸ در نتیجه لحاظ می‌شوند.

چه بگویید

هدف این ارائه یک پرسش بود: در اینترنت اشیا، آیا حذف انتقال دادهٔ خام در یادگیری فدرال، حریم خصوصی را حفظ می‌کند؟ و اگر نه، کدام روش کدام بخش از این شکاف را می‌بندد؟

آنچه به آن رسیدیم: پاسخ منفی است، و دلیلش فنی است نه شهودی. به‌روزرسانی مدل یک بردار عددی با ابعاد مدل است و بردار از نمونه اطلاع دارد؛ بازسازی از گرادیان یک کلاینت همین را نشان داد.

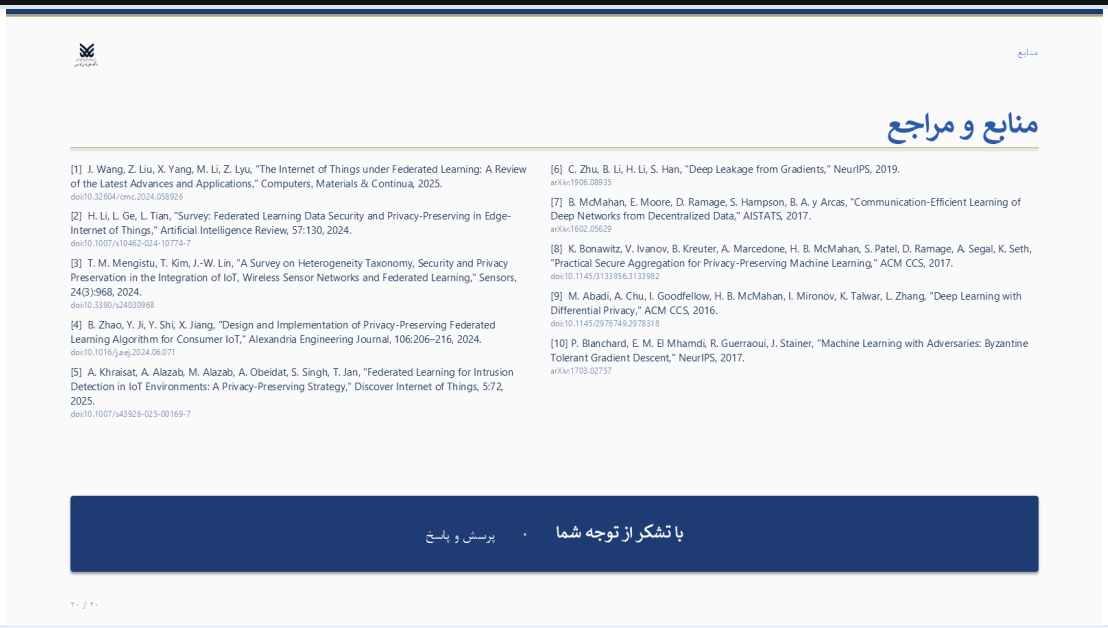
نتیجهٔ دوم: پنج مقاله یک الگوی مشترک دارند. هیچ دفاعی هر دو محور را نمی‌بندد؛ نویز تفاضلی کران ریاضی می‌دهد، رمزنگاری محرمانگی، تجمیع مقاوم یکپارچگی، و بلاک‌چین حسابرسی. سیستم‌های واقعی ترکیب‌اند: مقالهٔ [4] نویز و بلاک‌چین و شهرت را با هم دارد.

نتیجهٔ سوم و مهم‌ترین شکاف: در همین پنج مقاله کارایی گزارش شده ولی نشت اندازه‌گیری نشده. عدد ۹۵٫۰۵٪ فقط دقت تشخیص را می‌گوید؛ نمی‌گوید این مدل چقدر می‌تواند عضویت یک دستگاه را لو بدهد.

گام بعدی که پیشنهاد می‌کنیم: در کنار دقت و هشدار الکی، نشت را هم بسنجیم؛ با یک حملهٔ استنتاج عضویت و با گزارش بودجهٔ ε. تا وقتی این عدد در جدول‌ها نباشد، مقایسهٔ روش‌ها ناقص است.

هدف و پاسخ را جدا بگو | مرور نکن؛ نتیجه بده

انتقال: موژان → منابع



منابع

منابع و مراجع

[1] J. Wang, Z. Liu, X. Yang, M. Li, Z. Lyu, "The Internet of Things under Federated Learning: A Review of the Latest Advances and Applications," Computers, Materials & Continua, 2025.
doi:10.32604/cmc.2024.058926

[2] H. Li, L. Ge, L. Tian, "Survey: Federated Learning Data Security and Privacy-Preserving in Edge-Internet of Things," Artificial Intelligence Review, 57:130, 2024.
doi:10.1007/s10462-024-10774-7

[3] T. M. Mengistu, T. Kim, J.-W. Lin, "A Survey on Heterogeneity Taxonomy, Security and Privacy Preservation in the Integration of IoT, Wireless Sensor Networks and Federated Learning," Sensors, 24(3):968, 2024.
doi:10.3390/s24030968

[4] B. Zhao, Y. Ji, Y. Shi, X. Jiang, "Design and Implementation of Privacy-Preserving Federated Learning Algorithm for Consumer IoT," Alexandria Engineering Journal, 106:206–216, 2024.
doi:10.1016/j.aej.2024.06.071

[5] A. Khraisat, A. Alazab, M. Alazab, A. Obeidat, S. Singh, T. Jan, "Federated Learning for Intrusion Detection in IoT Environments: A Privacy-Preserving Strategy," Discover Internet of Things, 5:72, 2025.
doi:10.1007/s43926-025-00169-7

[6] C. Zhu, B. Li, H. Li, S. Han, "Deep Leakage from Gradients," NeurIPS, 2019.
arXiv:1906.08935

[7] B. McMahan, E. Moore, D. Ramage, S. Hampson, B. A. y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," AISTATS, 2017.
arXiv:1602.05629

[8] K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, "Practical Secure Aggregation for Privacy-Preserving Machine Learning," ACM CCS, 2017.
doi:10.1145/3133956.3133982

[9] M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, "Deep Learning with Differential Privacy," ACM CCS, 2016.
doi:10.1145/2976749.2978318

[10] P. Blanchard, E. M. El Mhamdi, R. Guerraoui, J. Stainer, "Machine Learning with Adversaries: Byzantine Tolerant Gradient Descent," NeurIPS, 2017.
arXiv:1703.02757

با تشکر از توجه شما · پرسش و پاسخ

۲۰ از ۲۰

۲۰

منابع و مراجع

موژان | مدت: ۰:۳۰ | تجمعی: ۳۰:۰۰ | پایان

پیام کلیدی: پنج مقالهٔ اصلی و پنج مرجع بنیادی؛ مسیر ادامهٔ مطالعه.

چرا این اسلاید: اعتبار و مسیر ادامهٔ مطالعه؛ مخاطب علاقه‌مند بداند از کجا شروع کند.

ربط با قبل: پایان مسیر؛ همان پنج مقالهٔ اسلاید ۴ و مراجع بنیادی دفاع‌ها.

چه بگویید

محتوای ارائه از پنج مقالهٔ [1] تا [5] آمده: سه مرور و دو چارچوب اجرایی.

پنج مرجع بنیادی هم پشت هر مفهوم ایستاده‌اند: بازسازی گرادیان [6]، میانگین‌گیری فدرال [7]، تجمیع امن [8]، حریم خصوصی تفاضلی [9]، و تجمیع مقاوم به خطای بیزانسی [10].

اگر خواستید ادامه بدهید، از مرور [2] و [3] شروع کنید؛ یکی نقشهٔ روش‌های رمزنگاری و نویز را می‌دهد و دیگری ناهمگونی داده را.

سپاس از توجه شما؛ آمادهٔ پرسش‌های شما هستیم.

تشکر | دعوت به پرسش

انتقال: پایان: پرسش‌وپاسخ