PRESENTER GUIDE · 30 MIN

بررسی روش‌های حفظ حریم خصوصی داده‌های شخصی در یادگیری فدرالِ اینترنت اشیا

راهنمای اسلاید به اسلاید برای دو ارائه‌دهنده؛ هر اسلاید شامل پیام کلیدی، متن پیشنهادی گفتار، نکته‌های اجرا و انتقال به اسلاید بعد است. زمان کل ۳۰ دقیقه است و برای چاپ A4 تنظیم شده است.

۲۰ اسلاید · ۳۰:۰۰ دقیقه · ۲ ارائه‌دهنده · هر اسلاید یک صفحهٔ چاپ

د

دیانا صباحی · ۱۵:۳۰

اسلایدهای ۱–۴، ۸–۱۰ و ۱۵–۱۷

م

موژان شجاعی · ۱۴:۳۰

اسلایدهای ۵–۷، ۱۱–۱۴ و ۱۸–۲۰

نقشهٔ زمانی

جمع: ۳۰:۰۰

ردیف	اسلاید	گوینده	زمان
۱	جلد	دیانا	۰:۳۰
۲	فهرست مطالب	دیانا	۱:۰۰
۳	مقدمه: مسئله، هدف و مسیر	دیانا	۲:۰۰
۴	روش انتخاب مقالات علمی	دیانا	۱:۳۰
۵	اینترنت اشیا چیست و چرا مهم است؟	موژان	۱:۳۰
۶	چرا آموزش متمرکز پاسخ نیست؟	موژان	۱:۳۰
۷	یادگیری فدرال چگونه کار می‌کند	موژان	۲:۰۰
۸	حریم خصوصی، ویژگی ذاتی یادگیری فدرال نیست	دیانا	۲:۰۰
۹	مدل تهدید	دیانا	۱:۳۰
۱۰	حملات؛ دو دسته	دیانا	۱:۳۰
۱۱	حریم خصوصی تفاضلی	موژان	۲:۰۰
۱۲	رمزنگاری	موژان	۱:۳۰
۱۳	بلاک‌چین	موژان	۱:۳۰
۱۴	تجمیع مقاوم	موژان	۱:۳۰
۱۵	مقایسهٔ روش‌ها در یک نگاه	دیانا	۲:۰۰
۱۶	خانهٔ هوشمند؛ یک معماری ترکیبی	دیانا	۱:۳۰
۱۷	تشخیص نفوذ با یادگیری فدرال	دیانا	۲:۰۰
۱۸	چالش‌ها و مسیر پیش‌رو	موژان	۱:۳۰
۱۹	جمع‌بندی و نتیجه	موژان	۱:۰۰
۲۰	منابع و مراجع	موژان	۰:۳۰

دیانا: ۱۵:۳۰ · موژان: ۱۴:۳۰

جمع کل: ۳۰:۰۰

اسلاید به اسلاید

متن گفتار پیشنهادی



۱ جلد

دیانا | مدت: ۰:۳۰ | تجمعی: ۰:۳۰ | **افتتاحیه**

پیام کلیدی: یک روز عادی با دستگاه‌های هوشمند؛ سپس یک پرسش: داده‌هایشان چه می‌شود؟

چه بگویید

یک روز عادی را تصور کنید: ساعت هوشمندتان ضربان قلب را می‌فرستد، ترموستات دمای خانه را تنظیم می‌کند و دوربین خانه رفت‌وآمد را ثبت می‌کند.

همین دستگاه‌ها موضوع سمینار ما هستند: اینترنت اشیا و حریم خصوصی داده‌هایشان در یادگیری فدرال.

من دیانا صباحی هستم و همراه موژان شجاعی در سی دقیقه از مسئله شروع می‌کنیم، تهدیدها و روش‌ها را می‌بینیم و در پایان یک چارچوب انتخاب روش ارائه می‌دهیم.

تماس چشمی و لبخند | اشاره به عنوان و پژوهشگران

انتقال: دیانا → فهرست مطالب



۲

فهرست مطالب

دیانا | مدت: ۱:۰۰ | تجمعی: ۱:۳۰ | **مسیر ارائه**

پیام کلیدی: مسیر شش‌بخشی و توزیع ۳۰ دقیقه.

چه بگویید

مثل یک سفر سی‌دقیقه‌ای است: اول می‌بینیم این دستگاه‌ها چه هستند، بعد خطرها را می‌شناسیم، بعد راه‌حل‌ها را مقایسه می‌کنیم.

ارائه شش بخش دارد: مقدمه و مسئله؛ اینترنت اشیا و یادگیری فدرال؛ تهدیدها و حملات؛ روش‌های دفاعی؛ مقایسه و مطالعات موردی؛ جمع‌بندی و نتیجه.

زمان کل سی دقیقه است. اگر زمان کم شد، جزئیات حملات را در پرسش‌وپاسخ توضیح می‌دهیم.

۳۰ دقیقه را یادآوری کن | به شش بخش اشاره کن

انتقال: دیانا → مقدمه



۳ مقدمه: مسئله، هدف و مسیر

دیانا | مدت: ۳:۰۰ | تجمعی: ۳:۳۰ | مقدمه

پیام کلیدی: یادگیری فدرال داده خام را جابه‌جا نمی‌کند، اما تضمین حریم خصوصی هم نمی‌دهد.

چه بگویید

ساعت هوشمند شما می‌داند کی می‌خوابید، ترموستات می‌داند کی خانه‌اید و دوربین می‌داند کی می‌آیید. این‌ها دادهٔ حساس‌اند.

در آموزش متمرکز، همهٔ این داده‌ها به یک سرور می‌رود؛ کاربر کنترل داده را از دست می‌دهد. هدف این ارائه، بررسی مقاله‌های علمی و مقایسهٔ روش‌های حفظ حریم خصوصی در یادگیری فدرال (FL) اینترنت اشیا است.

سه تعریف کوتاه: مدل یعنی الگوهای آموخته‌شده از داده؛ یادگیری یعنی پیدا کردن این الگوها از مثال‌ها؛ و FL یعنی آموزش مدل کنار داده، بدون جمع‌کردن داده در یک سرور.

چرا مدل و یادگیری لازم‌اند؟ دستگاه‌های اینترنت اشیا فقط داده تولید می‌کنند. بدون مدل، این داده‌ها فقط عدد و لاگ‌اند؛ مثلاً ساعت هوشمند فقط ضربان را نشان می‌دهد. با مدل، همان ساعت می‌گوید «این ضربان غیرعادی است». یادگیری هم لازم است، چون یک قاعدهٔ ثابت برای همهٔ خانه‌ها و بیماران جواب نمی‌دهد.

کاربردها هم واضح‌اند: تنظیم خودکار ترموستات، هشدار ضربان غیرعادی، تشخیص حرکت مشکوک در دوربین، و پیش‌بینی خرابی دستگاه در کارخانه.

پرسش اصلی: آیا یادگیری فدرال به‌تنهایی حریم خصوصی را تضمین می‌کند؟ پاسخ کوتاه: نه. FL داده خام را جابه‌جا نمی‌کند، اما به‌روزرسانی مدل می‌تواند حامل اطلاعات باشد.

مسیر: زمینه و مسئله، تهدیدها و دفاع‌ها، مقایسه و نتیجه. پس از این اسلاید، روش انتخاب مقالات علمی را می‌بینیم.

پاسخ «نه» را قلاب کن | هدف و روش را جدا بگو

انتقال: دیانا → روش انتخاب مقالات علمی



۴ روش انتخاب مقالات علمی

دیانا | مدت: ۱:۳۰ | تجمعی: ۵:۰۰ | روش‌شناسی

پیام کلیدی: ۲۹۳ رکورد، ۱ مقاله از زنجیرهٔ ارجاع، و نمونهٔ هدفمند ۵ مقاله.

چه بگویید

مثل پیدا کردن پنج کتاب خوب از بین صدها کتاب در کتابخانه: اول همه را می‌بینیم، بعد غربال می‌کنیم.

در ScienceDirect با کلیدواژه‌های IoT، federated learning و privacy/security در بازهٔ ۲۰۲۴–۲۰۲۵ جست‌وجو کردم؛ ۲۹۳ رکورد بازیابی شد. یک مقالهٔ کلیدی هم از زنجیرهٔ ارجاع اضافه شد.

معیار ورود: داوری همتا، انگلیسی، پیوند FL و IoT، و تمرکز بر حریم خصوصی یا امنیت؛ معیار خروج: خارج از بازه، غیرداوری، بدون پیوند موضوعی، یا نبود متن کامل.

در پایان پنج مقاله انتخاب کردم: سه مقاله و دو چارچوب. این پنج مقاله را خودم انتخاب کردم؛ پس نتیجه فقط دربارهٔ همین‌هاست، نه همهٔ پژوهش‌ها.

۲۹۳ و ۵ را بگو | بگو نمونه هدفمند است

انتقال: تحویل: دیانا این بخش را به موژان می‌سپارد.



۵ اینترنت اشیا چیست و چرا مهم است؟

موژان | مدت: ۱:۳۰ | تجمعی: ۶:۳۰ | **زمینه**

پیام کلیدی: اینترنت اشیا = دستگاه‌های روزمرهٔ متصل؛ دادهٔ حساس همین‌جاست.

چه بگویید

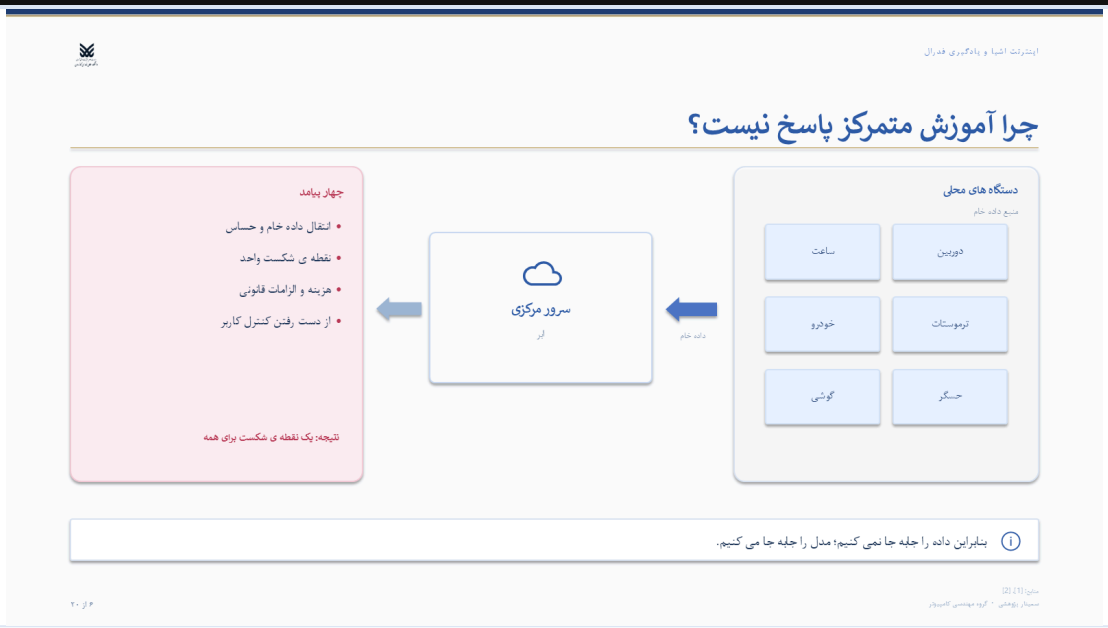
خانه‌تان را تصور کنید: ترموستات، دوربین، چراغ هوشمند، ساعت هوشمند و ماشین. همه حسگر دارند و داده می‌سازند.

اینترنت اشیا یعنی همین دستگاه‌های روزمره که به شبکه وصل‌اند و داده تولید می‌کنند. پنج حوزهٔ مهم: خانهٔ هوشمند، سلامت پوشیدنی، شهر هوشمند، صنعت متصل و حمل‌ونقل.

چرا مهم است؟ چون دادهٔ حساس همین‌جاست: عادت‌ها، ضربان، موقعیت و خط تولید. جمع‌کردن این داده‌ها در یک مرکز، هزینه، تأخیر و ریسک امنیتی دارد؛ برای همین باید حریم خصوصی را از همان دستگاه‌هایی که داده را می‌سازند شروع کنیم.

با مثال خانه شروع کن | تعریف و مثال را جدا بگو

انتقال: موژان → چرا آموزش متمرکز پاسخ نیست؟



۶ چرا آموزش متمرکز پاسخ نیست؟

موژان | مدت: ۱:۳۰ | تجمعی: ۸:۰۰ | **مسئله**

پیام کلیدی: تمرکز داده، چهار ریسک اصلی دارد.

چه بگویید

فرض کنید همهٔ داده‌های خانه، بیمارستان و کارخانه را در یک انبار بزرگ بریزیم. اگر یک بار انبار لو برود، همه چیز لو می‌رود.

در آموزش متمرکز، دستگاه‌ها دادهٔ خام را به سرور می‌فرستند. چهار پیامد دارد: انتقال دادهٔ حساس، نقطهٔ شکست واحد، هزینه و الزامات قانونی، و از دست رفتن کنترل کاربر.

یک سرور همهٔ داده‌ها را دارد؛ یک نفوذ می‌تواند همه را افشا کند. بنابراین ایده ساده است: داده را جابه‌جا نکنیم، مدل را جابه‌جا کنیم.

چهار پیامد را بشمار | گذار «مدل را جابه‌جا می‌کنیم»

انتقال: موژان → یادگیری فدرال



۷ یادگیری فدرال چگونه کار می‌کند

موژان | مدت: ۲:۰۰ | تجمعی: ۱۰:۰۰ | راه‌حل

پیام کلیدی: یادگیری = پیدا کردن الگو؛ FL = آموزش مدل کنار داده، نه بردن داده.

چه بگویید

یادگیری یعنی پیدا کردن الگو از مثال‌ها. مثل بچه‌ای که با دیدن صدها سیب و پرتقال، تفاوتشان را یاد می‌گیرد.

حالا سه بیمارستان را تصور کنید: هر کدام دادهٔ بیماران خودش را دارد و نمی‌خواهد داده را بفرستد. هر بیمارستان مدل را روی دادهٔ خودش آموزش می‌دهد و فقط وزن‌های مدل را می‌فرستد.

وزن یعنی چه؟ وزن یک عدد است که نشان می‌دهد هر ویژگی چقدر مهم است. مثلاً مدل یاد می‌گیرد برای تشخیص بیماری، «ضربان» وزن ۰٫۶ و «سن» وزن ۰٫۴ داشته باشد. آموزش یعنی پیدا کردن همین عددها.

FedAvg یا میانگین‌گیری فدرال یعنی سرور از وزن‌های همهٔ بیمارستان‌ها میانگین می‌گیرد. اگر سه بیمارستان وزن‌های A، B و C بفرستند، سرور مجموعشان را تقسیم بر سه می‌کند و مدل جدید را می‌سازد.

اگر بیمارستانی دادهٔ بیشتری داشته باشد، وزنش در میانگین بیشتر حساب می‌شود؛ مثل نظر پزشکی که بیماران بیشتری دیده است. بعد سرور مدل جدید را برمی‌گرداند و این چرخه چند دور تکرار می‌شود تا مدل بهتر شود.

این روش ساده و کم‌هزینه است، اما اگر داده‌ها خیلی متفاوت باشند یا دستگاهی خرابکار باشد، FedAvg به‌تنهایی کافی نیست.

یادگیری را با مثال بگو | سه بیمارستان را مثال بزن

انتقال: تحویل: موژان به دیانا.



۸ حریم خصوصی، ویژگی ذاتی یادگیری فدرال نیست

دیانا | مدت: ۳:۰۰ | تجمعی: ۱۲:۰۰ | **ادعای اصلی**

پیام کلیدی: بازسازی گرادیان، دادهٔ نمونه را افشا می‌کند.

چه بگویید

فرض کنید به جای عکس، فقط خلاصهٔ عکس را برایتان بفرستند. آیا از خلاصه می‌شود عکس را بازسازی کرد؟ بله، گاهی.

گرادیان چیست؟ وقتی مدل یک نمونه را می‌بیند، می‌فهمد چقدر اشتباه کرده و یک یادداشت کوچک می‌سازد: «این وزن‌ها را کمی کم یا زیاد کن.» به این یادداشت گرادیان می‌گوییم؛ یعنی جهت و مقدار اصلاح مدل.

Zhu و همکاران (۲۰۱۹) نشان دادند از همین گرادیان می‌توان تصویر یا متن را بازسازی کرد [6]. این حمله روی گرادیان یک دستگاه یا یک نمونه کار می‌کند، نه روی میانگین همهٔ دستگاه‌ها.

تجمیع امن یعنی سرور فقط جمع گرادیان‌ها را ببیند، نه گرادیان هر دستگاه را؛ مثل جمع کردن نامه‌های سربسته. DP یا حریم خصوصی تفاضلی یعنی کمی نویز اضافه کنیم تا حضور یک نفر در نتیجه گم شود. بنابراین اولین سؤال طراحی این است: چه کسی گرادیان‌های فردی را می‌بیند؟ اگر سرور تک‌تک را ببیند، خطر بازسازی دارد.

بازسازی از گرادیان فردی | میانگین تجمیع‌شده را جدا کن

انتقال: دیانا → مدل تهدید



۹ مدل تهدید

دیانا | مدت: ۱:۳۰ | تجمعی: ۱۳:۳۰ | **تهدیدها**

پیام کلیدی: سه بازیگر، دو دستهٔ حمله.

چه بگویید

در یک آزمون گروهی، سه نفر می‌توانند تقلب کنند: کسی که برگه‌ها را جمع می‌کند، کسی که برگهٔ جعلی می‌دهد، و کسی که وسط راه برگه را عوض می‌کند.

اینجا هم سه بازیگر داریم. اول سرور مرکزی که به‌روزرسانی مدل دستگاه‌ها را جمع و میانگین می‌گیرد. او تقلب نمی‌کند، اما می‌تواند به عددهای هر دستگاه نگاه کند.

مثال: سه بیمارستان هر کدام وزن‌های مدلشان را می‌فرستند؛ سرور جمع و میانگین می‌گیرد. اگر سرور عددهای هر بیمارستان را تک‌تک ببیند، ممکن است از آن‌ها اطلاعات بیماران را حدس بزند.

بازیگر دوم مشتری مخرب است که داده یا به‌روزرسانی را تحریف می‌کند؛ بازیگر سوم مهاجم شبکه است که در مسیر ارتباط شنود یا جعل هویت می‌کند.

از این سه بازیگر، دو دسته حمله شکل می‌گیرد: حملات علیه حریم خصوصی و حملات علیه یکپارچگی. هر دسته دفاع خودش را می‌طلبد.

حریم خصوصی یعنی اطلاعات شخصی لو نرود؛ کسی نفهمد چه کسی در آموزش بود یا چه ویژگی حساسی دارد. یکپارچگی یعنی مدل دستکاری نشود و پیش‌بینی‌ها قابل اعتماد بمانند.

سه بازیگر | دو دسته

انتقال: دیانا → حملات



۱۰ حملات؛ دو دسته

دیانا | مدت: ۱:۳۰ | تجمعی: ۱۵:۰۰ | **تهدیدها**

پیام کلیدی: حریم خصوصی و یکپارچگی را با هم اشتباه نگیریم.

چه بگویید

مثل دزدهایی که از پنجره، در و پشت‌بام وارد می‌شوند؛ هر کدام یک راه دارند.

حمله به حریم خصوصی یعنی مهاجم می‌خواهد بفهمد در داده چه بوده یا چه کسی در آموزش بوده. مثال ساده: کسی پروندهٔ پزشکی شما را بخواند. مشکلی که می‌سازد: افشای دادهٔ بیماران و کاربران، نقض قانون و از دست رفتن اعتماد.

پنج نمونهٔ مهم: استنتاج عضویت (آیا این شخص در آموزش بود؟)، استنتاج ویژگی (چه ویژگی حساسی از یک گروه لو می‌رود؟)، معکوس‌سازی مدل (بازسازی نمونهٔ نمایندهٔ یک کلاس)، بازسازی گرادیان (بازگرداندن تصویر یا متن از گرادیان)، و استخراج مدل (ساختن مدل تقلبی با کوئری).

حمله به یکپارچگی یعنی مهاجم مدل را دستکاری می‌کند تا نتیجه غلط شود. مثال ساده: کسی نسخهٔ پزشک را عوض کند. مشکلی که می‌سازد: پیش‌بینی غلط، هشدار اشتباه، رفتار پنهان مدل و تصمیم ناایمن.

پنج نمونهٔ مهم: مسموم‌سازی داده (دادهٔ آلوده)، درِ پشتی (محرک پنهان)، سایبیل (هویت جعلی)، بهره‌مندی بدون مشارکت (مشارکت بی‌ارزش)، و بیزانسی (خرابکاری هماهنگ).

سایبیل در عمل: یک مهاجم ۵۰ دستگاه جعلی وارد شبکه می‌کند تا وزن خرابکارانه در میانگین غالب شود. مثال روزمره: یک دانشجو با ۵۰ حساب جعلی در نظرسنجی کلاس رأی می‌دهد.

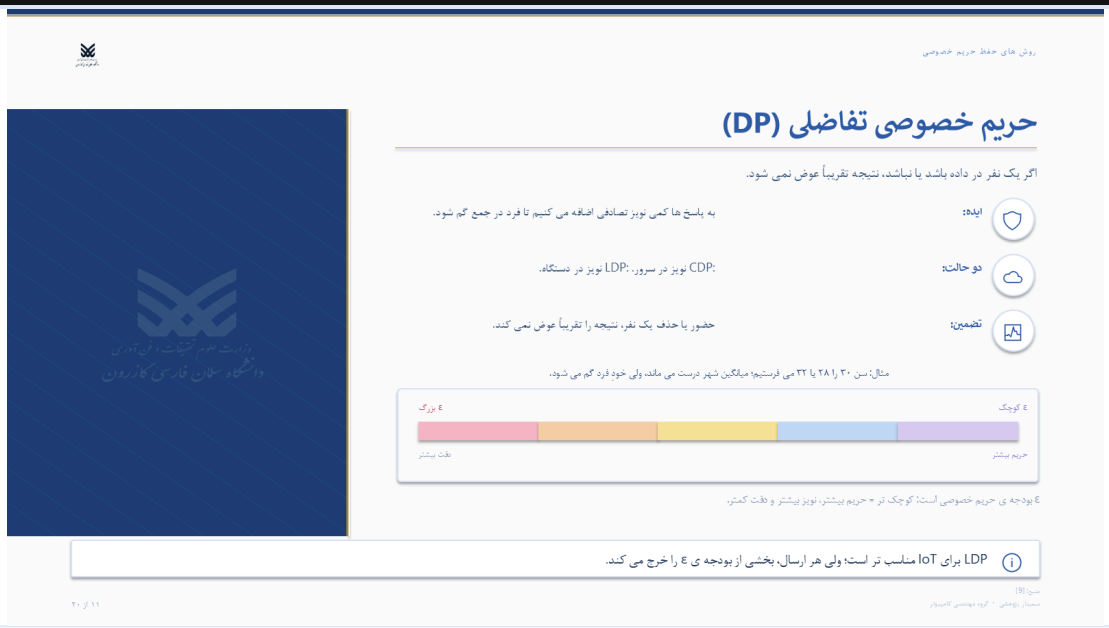
بهره‌مندی بدون مشارکت در عمل: دستگاهی بدون آموزش، وزن تکراری یا صفر می‌فرستد و پاداش می‌گیرد. مثال روزمره: عضو گروهی که هیچ کاری نمی‌کند، اما نمرهٔ گروه را می‌گیرد.

بیزانسی در عمل: چند دستگاه هماهنگ وزن‌های خراب می‌فرستند تا مدل مشترک اشتباه کند. مثال روزمره: چند نفر هماهنگ جواب غلط می‌دهند تا پروژه خراب شود.

نکته: بازسازی معمولاً از گرادیان فردی انجام می‌شود، نه از میانگین تجمیع‌شده.

یک مثال برای هر دسته | بازسازی از گرادیان فردی

انتقال: تحویل: دیانا به موژان برای دفاع‌ها.



۱۱ حریم خصوصی تفاضلی

موژان | مدت: ۲:۰۰ | تجمعی: ۱۷:۰۰ | دفاع‌ها

پیام کلیدی: DP تنها روشی است که تضمین ریاضی می‌دهد؛ ε اندازهٔ نویز است.

چه بگویید

یک نظرسنجی ساده را تصور کنید: سن، شهر، شغل. اگر جواب‌ها به‌اندازهٔ کافی خاص باشند، همین سه عدد مثل اثر انگشت می‌شود؛ «۳۳ ساله، از یک شهر کوچک، با یک شغل خاص» شاید در تمام شهر فقط یک نفر باشد.

راه‌حل ساده: قبل از فرستادن جواب، به عدد خودتان کمی نویز اضافه کنید. نویز یعنی تغییر تصادفی و کوچک؛ به ۳۰ سال بگویید ۲۸ یا ۳۲، به ۱۲ هزار قدم بگویید ۱۱٫۵ یا ۱۲٫۵ هزار. این دروغ نیست؛ خطای عمدی و کنترل‌شده است.

چرا نتیجه خراب نمی‌شود؟ چون خطاها دو طرفه‌اند: یکی ۲ سال کم می‌گوید، یکی ۲ سال زیاد؛ در جمع همدیگر را می‌خورند. مثل این‌که از ۱۰۰ نفر بخواهیم وزنشان را گرد کنند؛ میانگین تقریباً همان می‌ماند.

حریم خصوصی تفاضلی همین کار را با تضمین ریاضی انجام می‌دهد: اگر شما در نظرسنجی باشید یا نباشید، خروجی منتشرشده تقریباً یکسان است. پس حتی اگر مهاجم بقیهٔ داده‌ها را بداند، نمی‌تواند بفهمد شما بوده‌اید یا نه.

CDP و LDP: در CDP همه جواب درست را به یک دفتر مطمئن می‌دهند؛ دفتر خودش نویز می‌زند و منتشر می‌کند، پس باید به آن دفتر اعتماد کنید. در LDP نویز را قبل از فرستادن، روی گوشی خودتان می‌زنید؛ سرور هیچ‌وقت عدد واقعی را نمی‌بیند، پس لازم نیست به آن اعتماد کنید.

ε یعنی چقدر نویز. کوچک‌تر = حریم بیشتر، نویز بیشتر، دقت کمتر. با ε بزرگ می‌توانید میانگین سن شهر را منتشر کنید، ولی نه «چند نفر ۳۰ ساله‌اند». در IoT مشکل اصلی این است که دستگاه هر چند دقیقه یک بار می‌فرستد؛ اگر هر بار نویز مستقل بزنید، مهاجم با میانگین گرفتن از هزار پیام، نویز را پاک می‌کند. پس LDP مناسب‌تر است، ولی بودجه باید بین چند دور تقسیم شود.

فرمول را سریع رد نکن | ε را به نویز و دقت وصل کن

انتقال: موژان → رمزنگاری



۱۲ رمزنگاری

موژان | مدت: ۱:۳۰ | تجمعی: ۱۸:۳۰ | دفاع‌ها

پیام کلیدی: رمزنگاری محرمانگی می‌دهد، نه لزوماً تضمین DP.

چه بگویید

نامه‌ای را در پاکت قفل‌شده بفرستید؛ پستچی آدرس را می‌بیند، اما متن نامه را نمی‌بیند.

تجمیع امن: هر دستگاه عددش را در پاکت سربسته می‌گذارد؛ سرور فقط جمع را می‌بیند، نه عدد هر دستگاه [8].

SMPC: چند نفر با هم یک محاسبه انجام می‌دهند، بدون اینکه عددشان را به دیگری بگویند؛ مثل رأی‌گیری مخفی.

HE: داده را در جعبهٔ قفل‌شده می‌گذاریم و روی همان جعبه حساب می‌کنیم؛ بدون بازکردن جعبه.

تقسیم دادهٔ محرمانه: دادهٔ محرمانه را به چند تکه تقسیم می‌کنیم و به چند نفر می‌دهیم؛ فقط با کنار هم گذاشتن تکه‌ها داده کامل می‌شود.

هزینه: این روش‌ها محاسبات سنگین‌تری دارند؛ روی ساعت یا حسگر کوچک، باتری و زمان بیشتری می‌گیرند. مهم‌تر: این روش‌ها فقط محرمانگی می‌دهند؛ یعنی محتوا را از سرور پنهان می‌کنند. اما تضمین DP نیستند؛ یعنی ممکن است از مدل نهایی باز هم اطلاعات فردی لو برود. جلوی مسموم‌سازی را هم نمی‌گیرند؛ اگر دستگاه خرابکار عدد غلط بفرستد، آن عدد غلط هم مخفی می‌شود. مثال: نامهٔ سربسته با عدد غلط؛ سرور متن را نمی‌بیند، ولی جمع نهایی غلط می‌شود.

محرمانگی ≠ DP | هزینه‌ها را مقایسه کن

انتقال: موژان → بلاک‌چین



۱۳ بلاک‌چین

موژان | مدت: ۱:۳۰ | تجمعی: ۲۰:۰۰ | دفاع‌ها

پیام کلیدی: بلاک‌چین وابستگی را کم می‌کند، محرمانگی نمی‌دهد.

چه بگویید

دفتر حضور و غیاب کلاس را تصور کنید که هر دانشجو یک نسخه از آن دارد. اگر یک نفر غیبت را به حضور تغییر دهد، بقیه نسخه‌ها با او نمی‌خوانند و تغییر رد می‌شود.

بلاک‌چین همین دفتر مشترک است: نیازی به یک مدیر مرکزی نیست. هر دستگاه به‌روزرسانی را امضا می‌کند (مثل مهر شخصی)، قرارداد هوشمند قواعد را خودکار بررسی می‌کند (مثل ماشین فروش خودکار)، و مدل و پاداش ثبت می‌شود.

همه می‌توانند تاریخچه را ببینند و دستکاری لو می‌رود؛ این یعنی حسابرسی‌پذیر. اما محرمانگی محتوا را تضمین نمی‌کند؛ اگر داده رمز نشده باشد، ممکن است دیده شود.

مدل بزرگ در IPFS (انبار فایل توزیع‌شده) می‌ماند و فقط اثر انگشت دیجیتال (هش) آن روی زنجیره ثبت می‌شود. هزینه‌اش تأخیر اجماع است: برای ثبت هر مورد باید همهٔ نسخه‌ها تأیید کنند؛ برای هزاران دستگاه کوچک هم مقیاس‌پذیری محدود است.

بلاک‌چین محرمانگی نمی‌دهد | تأخیر اجماع

انتقال: موژان → تجمیع مقاوم



۱۴ تجمیع مقاوم

موژان | مدت: ۱:۳۰ | تجمعی: ۲۱:۳۰ | دفاع‌ها

پیام کلیدی: **تجمیع مقاوم برای یکپارچگی است، نه حریم خصوصی.**

چه بگویید

در یک رأی‌گیری، چند رأی تقلبی می‌آید؛ می‌توانیم رأی‌های دور از اکثریت را کنار بگذاریم.

تجمیع مقاوم با به‌روزرسانی‌های پرت سروکار دارد: Krum، میانهٔ بریده‌شده، فیلتر پرت یک‌بعدی و آموزش خصمانه [10].

به‌روزرسانی‌های دور از اکثریت، پیش از تجمیع کنار گذاشته می‌شوند. این روش‌ها فقط یکپارچگی را حفظ می‌کنند؛ حریم خصوصی را تضمین نمی‌کنند. بنابراین در کنار DP یا رمزنگاری معنا دارند، نه به‌جای آن‌ها.

یکپارچگی ≠ حریم خصوصی | Krum را نام ببر

انتقال: تحویل: موژان به دیانا برای مقایسه.



۱۵ مقایسهٔ روش‌ها در یک نگاه

دیانا | مدت: ۲:۰۰ | تجمعی: ۲۳:۳۰ | مقایسه

پیام کلیدی: انتخاب روش به تهدید، بودجه و توان دستگاه بستگی دارد.

چه بگویید

مثل انتخاب وسیله برای سفر: دوچرخه، ماشین یا قطار؛ هیچ‌کدام همیشه بهترین نیست.

جدول را ستون‌به‌ستون بخوانیم. DP: تضمین رسمی با ε، تهدید سرور کنجکاو، هزینهٔ متوسط و بلوغ بالا. تجمیع امن / SMPC: محرمانگی به‌روزرسانی‌ها، تهدید سرور یا شبکه، بدون ε و هزینهٔ متوسط. HE: محرمانگی محاسبه، هزینهٔ بسیار زیاد و بلوغ پایین.

بلاک‌چین: یکپارچگی و حسابرسی، نه محرمانگی؛ هزینهٔ زیاد. تجمیع مقاوم: یکپارچگی و هزینهٔ کم. انتخاب روش به تهدید، بودجه و توان دستگاه بستگی دارد.

ستون‌ها را از راست بخوان | «بدون ε» را توضیح بده

انتقال: دیانا → خانهٔ هوشمند



۱۶ خانهٔ هوشمند؛ یک معماری ترکیبی

دیانا | مدت: ۱:۳۰ | تجمعی: ۲۵:۰۰ | **مطالعهٔ موردی**

پیام کلیدی: یک سناریوی مفهومی برای ترکیب روش‌ها.

چه بگویید

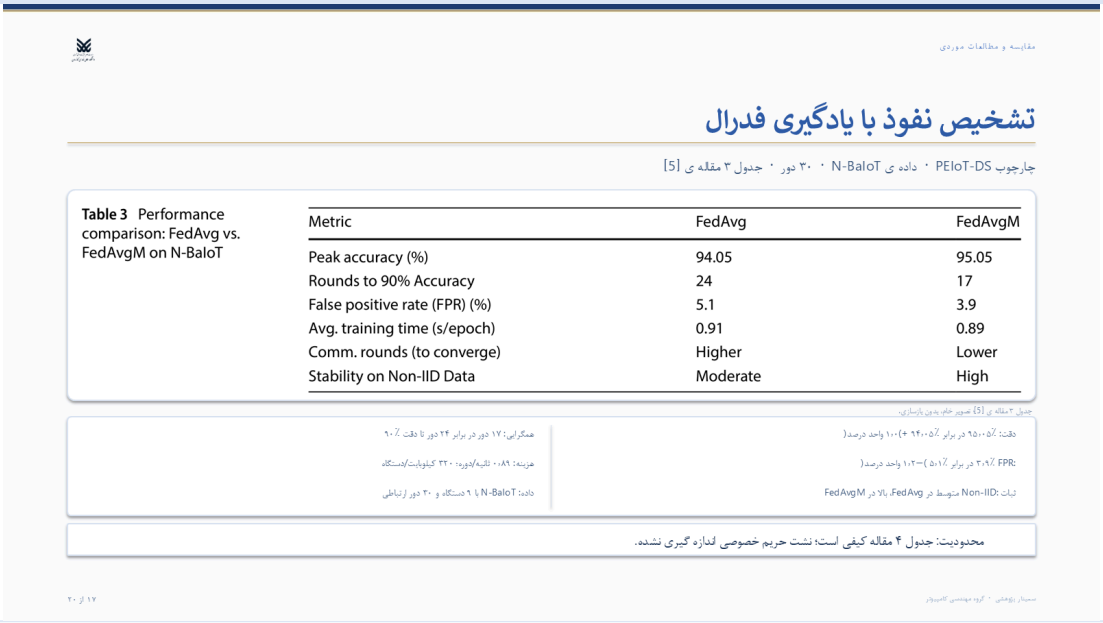
یک خانهٔ واقعی را تصور کنید: ترموستات، دوربین، گوشی، یک سرور محله، بلاک‌چین و سازنده.

لوازم خانگی دادهٔ محلی را نگه می‌دارند؛ گوشی نویز DP اضافه می‌کند؛ سرور محلی لایه‌ها را آموزش می‌دهد؛ بلاک‌چین تجمیع و پاداش را ثبت می‌کند؛ سازنده مدل مشترک را می‌گیرد.

چه چیزی محافظت می‌شود؟ دادهٔ خام در خانه می‌ماند، DP پیش از خروج ویژگی‌ها اعمال می‌شود و امضای دیجیتال مانع جعل می‌شود. چه هزینه‌ای دارد؟ هماهنگی گوشی، سرور محلی و بلاک‌چین؛ تأخیر اجماع و ذخیره‌سازی مدل. این معماری ترکیبی است، نه یک روش واحد.

بگو مفهومی است | پنج مؤلفه را دنبال کن

انتقال: دیانا → تشخیص نفوذ



مقایسه و مطالعات موردی

تشخیص نفوذ با یادگیری فدرال

چارچوب PEIoT-DS · داده ی N-BaIoT · ۳۰ دور · جدول ۳ مقاله ی [5]

Table 3 Performance comparison: FedAvg vs. FedAvgM on N-BaIoT

Metric	FedAvg	FedAvgM
Peak accuracy (%)	94.05	95.05
Rounds to 90% Accuracy	24	17
False positive rate (FPR) (%)	5.1	3.9
Avg. training time (s/epoch)	0.91	0.89
Comm. rounds (to converge)	Higher	Lower
Stability on Non-IID Data	Moderate	High

جدول ۳ مقاله ی [5] تصویر خام، بدون پارسازی.

دقت: ٪۹۵۰۰۵ در برابر ٪۹۴۰۰۵ (+۱۰۰ واحد درصد)

FPR: ٪۳٫۹ در برابر ٪۵٫۱ (−۱٫۲۰ واحد درصد)

ثبات: Non-IID متوسط در FedAvg، بالا در FedAvgM

همگرایی: ۱۷ دور در برابر ۲۴ دور تا دقت ٪۹۰

هزینه: ۰٫۸۹ ثانیه/دوره؛ ۳۲۰ کیلوبایت/دستگاه

داده: N-BaIoT با ۹ دستگاه و ۳۰ دور ارتباطی

محدودیت: جدول ۴ مقاله کیفی است؛ نشت حریم خصوصی اندازه گیری نشده.

سمینار پژوهشی · گروه مهندسی کامپیوتر

۱۷ از ۲۰

۱۷ تشخیص نفوذ با یادگیری فدرال

دیانا | مدت: ۲:۰۰ | تجمعی: ۲۷:۰۰ | **مطالعهٔ موردی**

پیام کلیدی: جدول ۳: دقت ٪۹۵٫۰۵ و FPR ٪۳٫۹؛ بدون سنجش نشت.

چه بگویید

یک شبکهٔ کوچک را تصور کنید که حمله می‌شود؛ می‌خواهیم مدل، حمله را زود تشخیص دهد.

روی اسلاید، جدول ۳ مقاله را همان‌طور که منتشر شده می‌بینید؛ اعداد را بازسازی نکرده‌ام. FedAvg دقت ۹۴٫۰۵ و FedAvgM دقت ۹۵٫۰۵ دارد؛ نرخ مثبت کاذب از ۵٫۱ به ۳٫۹ کاهش می‌یابد؛ تعداد دور تا دقت ٪۹۰ از ۲۴ به ۱۷ می‌رسد.

آموزش محلی ۰٫۸۹ ثانیه در هر دوره و ارتباط هر دستگاه ۳۲۰ کیلوبایت است [5، جدول ۳]. FedAvgM سریع‌تر و پایدارتر است. محدودیت: جدول ۴ مقاله فقط کیفی است و نشت حریم خصوصی اندازه‌گیری نشده؛ پس این مطالعه عملکرد IDS را می‌سنجد، نه تضمین حریم خصوصی را.

جدول ۳ را نشان بده | محدودیت مطالعه را بگو

انتقال: تحویل: دیانا به موژان برای جمع‌بندی.



۱۸ چالش‌ها و مسیر پیش‌رو

موژان | مدت: ۱:۳۰ | تجمعی: ۲۸:۳۰ | جمع‌بندی

پیام کلیدی: چهار چالش، سه مسیر، یک ملاحظهٔ قانونی.

چه بگویید

مثل ورزشکاری که هم سرعت می‌خواهد هم دقت؛ نمی‌شود هر دو را بی‌هزینه داشت.

چهار چالش اصلی: ناهمگونی داده یا Non-IID؛ محدودیت منابع باتری و پردازنده؛ بده‌بستان حریم خصوصی و دقت؛ و نبود بنچمارک مشترک.

سه مسیر پیش‌رو: ترکیب لایه‌ها، رمزنگاری سبک‌وزن و مدل شخصی‌سازی‌شده. ملاحظات قانونی هم داریم: رضایت، کمینه‌سازی داده و انطباق با GDPR.

در پنج مقالهٔ علمی بررسی‌شده، هیچ روشی به‌تنهایی کافی نبود.

چهار چالش | سه مسیر + قانون

انتقال: موژان → نتیجه



۱۹

جمع‌بندی و نتیجه

موژان | مدت: ۱:۰۰ | تجمعی: ۲۹:۳۰ | جمع‌بندی

پیام کلیدی: ضرورت، نتیجه و گام بعدی.

چه بگویید

اگر بخواهیم کل ارائه را در یک جمله بگوییم: دادهٔ حساس را از دستگاه بیرون نفرستیم، اما مدل را هوشمند نگه داریم.

نتیجه: یادگیری فدرال داده را جابه‌جا نمی‌کند، اما به‌روزرسانی‌ها را جابه‌جا می‌کند؛ چهار دستهٔ دفاعی با هزینه‌های متفاوت داریم؛ سیستم‌های واقعی همیشه ترکیبی‌اند.

ضرورت انتخاب موضوع: رشد پرشتاب دستگاه‌ها و داده‌های حساس، شکاف میان ادعای FL و تضمین واقعی، و نیاز به چارچوب انتخاب روش.

کاری که می‌توانم انجام دهم: ارزیابی ترکیب DP و تجمیع امن روی یک بنچمارک واقعی IoT. جملهٔ پایانی: ٪۹۵ دقت، بدون سنجش نشت حریم خصوصی.

سه جملهٔ نتیجه | گام بعدی

انتقال: موژان → منابع


منابع

منابع و مراجع

[1] J. Wang, Z. Liu, X. Yang, M. Li, Z. Lyu, "The Internet of Things under Federated Learning: A Review of the Latest Advances and Applications," Computers, Materials & Continua, 2025.
doi:10.32604/cmc.2024.058926

[2] H. Li, L. Ge, L. Tian, "Survey: Federated Learning Data Security and Privacy-Preserving in Edge-Internet of Things," Artificial Intelligence Review, 57:130, 2024.
doi:10.1007/s10462-024-10774-7

[3] T. M. Mengistu, T. Kim, J.-W. Lin, "A Survey on Heterogeneity Taxonomy, Security and Privacy Preservation in the Integration of IoT, Wireless Sensor Networks and Federated Learning," Sensors, 24(3):968, 2024.
doi:10.3390/s24030968

[4] B. Zhao, Y. Ji, Y. Shi, X. Jiang, "Design and Implementation of Privacy-Preserving Federated Learning Algorithm for Consumer IoT," Alexandria Engineering Journal, 106:206–216, 2024.
doi:10.1016/j.aej.2024.06.071

[5] A. Khraisat, A. Alazab, M. Alazab, A. Obeidat, S. Singh, T. Jan, "Federated Learning for Intrusion Detection in IoT Environments: A Privacy-Preserving Strategy," Discover Internet of Things, 5:72, 2025.
doi:10.1007/s43926-025-00169-7

[6] C. Zhu, B. Li, H. Li, S. Han, "Deep Leakage from Gradients," NeurIPS, 2019.
arXiv:1906.08935

[7] B. McMahan, E. Moore, D. Ramage, S. Hampson, B. A. y Arcas, "Communication-Efficient Learning of Deep Networks from Decentralized Data," AISTATS, 2017.
arXiv:1602.05629

[8] K. Bonawitz, V. Ivanov, B. Kreuter, A. Marcedone, H. B. McMahan, S. Patel, D. Ramage, A. Segal, K. Seth, "Practical Secure Aggregation for Privacy-Preserving Machine Learning," ACM CCS, 2017.
doi:10.1145/3133956.3133982

[9] M. Abadi, A. Chu, I. Goodfellow, H. B. McMahan, I. Mironov, K. Talwar, L. Zhang, "Deep Learning with Differential Privacy," ACM CCS, 2016.
doi:10.1145/2976749.2978318

[10] P. Blanchard, E. M. El Mhamdi, R. Guerraoui, J. Stainer, "Machine Learning with Adversaries: Byzantine Tolerant Gradient Descent," NeurIPS, 2017.
arXiv:1703.02757

با تشکر از توجه شما · پرسش و پاسخ

۲۰

منابع و مراجع

موژان · مدت: ۰:۳۰ · تجمعی: ۳۰:۰۰ · پایان

پیام کلیدی: منابع کلیدی برای پیگیری.

چه بگویید

منابع مثل نقشهٔ راه هستند؛ اگر خواستید بیشتر بخوانید، از همین‌ها شروع کنید.

منابع اصلی: پنج مقالهٔ ۲۰۲۴–۲۰۲۵ و پنج مرجع بنیادی؛ از FedAvg و Secure Aggregation تا DP و Krum.

از توجه شما ممنونم؛ آمادهٔ پرسش‌وپاسخ هستم.

تشکر · دعوت به پرسش

انتقال: پایان: پرسش‌وپاسخ